

**ANKARA ÜNİVERSİTESİ
MÜHENDİSLİK FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ**



BLM 4522 PROJE RAPORU

Ağ Tabanlı Paralel Dağıtım Sistemleri

Final 2. Proje

Veri Temizleme ve ETL Süreçleri Tasarımı

<https://github.com/zeyneph61/Ag-Tabanlı-Paralel-Dağıtım-Sistemleri-Projeleri>

<https://www.youtube.com/watch?v=HdGlojIVm58>

Zeynep Hacısalıhoğlu

22290449

İÇİNDEKİLER

İÇİNDEKİLER	3
1. GİRİŞ	4
1.1 Amaç ve Kapsam	4
1.2 Kullanılan Ortam.....	4
1.3 Veri Tabanı Kurulumu.....	4
2. Veri Analizi (Extract).....	5
2.1 NULL Değerlerin Tespiti	5
2.2 Tutarsız Veri Kontrolü	6
2.3 Kirli Veri Tespiti.....	7
3. Veri Temizleme ve Dönüştürme (Transform)	8
3.1 Hatalı Verilerin Temizlenmesi	8
3.2 Veri Dönüştürme ve Standartlaştırma.....	9
4. Veri Yükleme (Load)	10
4.1 Hedef Tablonun Oluşturulması ve Veri Yüklenmesi	10
5. Veri Kalitesi Raporu	11
5.1 ETL Sonrası Veri Kalitesi Analizi	11
6. Sonuç.....	12

1. GİRİŞ

Bu proje kapsamında Microsoft SQL Server 2022 üzerinde çalışan Northwind veritabanında ETL (Extract, Transform, Load) süreçleri tasarlanmış ve uygulanmıştır. Veri temizleme, dönüştürme ve yükleme adımları T-SQL kullanılarak gerçekleştirilmiş; sürecin sonunda veri kalitesi raporları oluşturulmuştur.

1.1 Amaç ve Kapsam

Çalışmanın temel amacı Northwind veritabanındaki hatalı, eksik ve tutarsız verileri tespit ederek temizlemek, dönüştürmek ve hazırlanan veriyi hedef tablolara yüklemektir.

Bu doğrultuda aşağıdaki adımlar uygulanmıştır:

- Kaynak veriler analiz edilerek eksik ve tutarsız değerler tespit edilmiştir.
- Hatalı veriler T-SQL ile temizlenmiştir.
- Veriler standart formata dönüştürülmüştür.
- Temizlenmiş veriler hedef tabloya yüklenmiştir.
- Veri kalitesi raporu oluşturulmuştur.

1.2 Kullanılan Ortam

- Veritabanı Sistemi: Microsoft SQL Server 2022 Developer Edition, Sürüm 16.0.1000.6
- Yönetim Aracı: SQL Server Management Studio (SSMS)

1.3 Veri Tabanı Kurulumu

Proje kapsamında kullanılacak örnek veritabanı olarak Northwind seçilmiştir. Northwind, Microsoft tarafından yayımlanmış; bir ticaret şirketinin sipariş, ürün,

müşteri ve çalışan verilerini barındıran klasik bir örnek veritabanıdır. Veritabanı SSMS üzerinden başarıyla yüklenmiş ve önceki projelerde doğrulanmıştır.

2. Veri Analizi (Extract)

2.1 NULL Değerlerin Tespiti

ETL sürecinin ilk aşamasında kaynak verilerin kalitesi analiz edilmiştir. Customers, Orders ve Products tablolarındaki NULL değerler sorgulanmıştır.

```
SELECT
    'Customers' AS table_name,
    COUNT(*) AS total_rows,
    SUM(CASE WHEN CompanyName IS NULL THEN 1 ELSE 0 END) AS null_companyname,
    SUM(CASE WHEN ContactName IS NULL THEN 1 ELSE 0 END) AS null_contactname,
    SUM(CASE WHEN Phone IS NULL THEN 1 ELSE 0 END) AS null_phone,
    SUM(CASE WHEN Region IS NULL THEN 1 ELSE 0 END) AS null_region,
    SUM(CASE WHEN PostalCode IS NULL THEN 1 ELSE 0 END) AS null_postalcode
FROM Customers;
```

Customers tablosunda 1 eksik telefon, 61 eksik bölge ve 2 eksik posta kodu tespit edilmiştir.

	table_name	total_rows	null_companyname	null_contactname	null_phone	null_region	null_postalcode
1	Customers	92	0	0	1	61	2

```
SELECT
    'Orders' AS table_name,
    COUNT(*) AS total_rows,
    SUM(CASE WHEN ShipName IS NULL THEN 1 ELSE 0 END) AS null_shipname,
    SUM(CASE WHEN ShipAddress IS NULL THEN 1 ELSE 0 END) AS null_shipaddress,
    SUM(CASE WHEN ShipCity IS NULL THEN 1 ELSE 0 END) AS null_shipcity,
    SUM(CASE WHEN ShipRegion IS NULL THEN 1 ELSE 0 END) AS null_shipregion,
    SUM(CASE WHEN ShippedDate IS NULL THEN 1 ELSE 0 END) AS null_shippeddate
FROM Orders

UNION ALL

SELECT
    'Products' AS table_name,
    COUNT(*) AS total_rows,
    SUM(CASE WHEN ProductName IS NULL THEN 1 ELSE 0 END) AS null_productname,
    SUM(CASE WHEN QuantityPerUnit IS NULL THEN 1 ELSE 0 END) AS null_quantityperunit,
    SUM(CASE WHEN UnitPrice IS NULL THEN 1 ELSE 0 END) AS null_unitprice,
    SUM(CASE WHEN UnitsInStock IS NULL THEN 1 ELSE 0 END) AS null_unitsinstock,
    SUM(CASE WHEN ReorderLevel IS NULL THEN 1 ELSE 0 END) AS null_reorderlevel
FROM Products;
```

Orders tablosunda 507 eksik bölge ve 21 gönderilmemiş sipariş tespit edilmiştir.

Products tablosunda NULL değer bulunmamaktadır.

	table_name	total_rows	null_shipname	null_shipaddress	null_shipcity	null_shipregion	null_shippeddate
1	Orders	830	0	0	0	507	21
2	Products	77	0	0	0	0	0

2.2 Tutarsız Veri Kontrolü

Fazla boşluk ve tutarsız Country değerleri kontrol edilmiştir.

```
SELECT CustomerID, CompanyName, ContactName
FROM Customers
WHERE CompanyName != LTRIM(RTRIM(CompanyName))
   OR ContactName != LTRIM(RTRIM(ContactName));

SELECT DISTINCT Country, LEN(Country) AS length
FROM Customers
ORDER BY Country;
```

CompanyName ve ContactName kolonlarında fazla boşluk tespit edilmemiştir.

Country kolonunda NULL değer bulunduğu görülmüştür.

[illegible]

2.3 Kirli Veri Tespiti

Country değeri NULL olan kayıtlar aşağıdaki sorgu ile tespit edilmiştir.

```
SELECT CustomerID, CompanyName, ContactName, Country, Region
FROM Customers
WHERE Country IS NULL;
```

Sorgu sonucunda CustomerID'si "TEST" olan bir test kaydı tespit edilmiştir. Bu kaydın CompanyName, ContactName ve diğer alanları da anlamsız verilerden oluşmaktadır.

	CustomerID	CompanyName	ContactName	Country	Region
1	TEST	Test Firma	Mr	NULL	NULL

3. Veri Temizleme ve Dönüştürme (Transform)

3.1 Hatalı Verilerin Temizlenmesi

Analiz aşamasında tespit edilen hatalı ve eksik veriler aşağıdaki T-SQL komutları ile temizlenmiştir. Test kaydı silinmiş, NULL bölge ve posta kodu değerleri 'N/A' ile doldurulmuştur.


```
--Test kaydını sil
DELETE FROM Customers WHERE CustomerID = 'TEST';

-- NULL Region değerlerini 'N/A' ile doldur
UPDATE Customers
SET Region = 'N/A'
WHERE Region IS NULL;

-- NULL PostalCode değerlerini 'N/A' ile doldur
UPDATE Customers
SET PostalCode = 'N/A'
WHERE PostalCode IS NULL;

-- Orders tablosundaki NULL ShipRegion değerlerini 'N/A' ile doldur
UPDATE Orders
SET ShipRegion = 'N/A'
WHERE ShipRegion IS NULL;
```

İşlem sonucunda 1 test kaydı silinmiş, 60 Region ve 1 PostalCode değeri güncellenmiş, Orders tablosunda 507 ShipRegion değeri 'N/A' olarak işaretlenmiştir.

 İletiler

```
(1 satır etkilendi)

(60 satır etkilendi)

(1 satır etkilendi)

(507 satır etkilendi)

Tamamlanma süresi:2026-05-17T15:37:11.1668633+03:00
```

3.2 Veri Dönüştürme ve Standartlaştırma

Customers tablosundaki Country değerlerinin büyük/küçük harf tutarlılığı sağlanmış, ContactTitle kolonundaki fazla boşluklar temizlenmiştir. Ayrıca Products tablosundaki Discontinued kolonu doğrulanmıştır.

```

-- Country değerlerini standartlaştır
UPDATE Customers
SET Country = UPPER(LEFT(Country, 1)) + LOWER(SUBSTRING(Country, 2, LEN(Country)))
WHERE Country IS NOT NULL;

-- ContactTitle boşluklarını temizle
UPDATE Customers
SET ContactTitle = LTRIM(RTRIM(ContactTitle));

-- Discontinued kontrolü
SELECT ProductID, ProductName, Discontinued
FROM Products
WHERE Discontinued NOT IN (0, 1);

```

Discontinued kolonunda tutarsız değer bulunmamıştır. Country ve ContactTitle değerleri başarıyla standartlaştırılmıştır.

ProductID	ProductName	Discontinued
-----------	-------------	--------------

4. Veri Yükleme (Load)

4.1 Hedef Tablonun Oluşturulması ve Veri Yüklmesi

Temizlenen ve dönüştürülen veriler yeni bir hedef tabloya yüklenmiştir. Hedef tablo, kaynak tabloya ek olarak ETL yükleme tarihini de kayıt altına alan ETL_LoadDate kolonunu içermektedir.

```
CREATE TABLE Customers_Cleaned (  
    CustomerID NCHAR(5) PRIMARY KEY,  
    CompanyName NVARCHAR(40) NOT NULL,  
    ContactName NVARCHAR(30),  
    ContactTitle NVARCHAR(30),  
    Phone NVARCHAR(24),  
    Country NVARCHAR(15),  
    Region NVARCHAR(15),  
    PostalCode NVARCHAR(10),  
    ETL_LoadDate DATETIME DEFAULT GETDATE()  
);  
  
-- Temizlenmiş veriyi yükle  
INSERT INTO Customers_Cleaned  
    (CustomerID, CompanyName, ContactName, ContactTitle, Phone, Country, Region, PostalCode)  
SELECT  
    CustomerID, CompanyName, ContactName, ContactTitle, Phone, Country, Region, PostalCode  
FROM Customers  
WHERE Country IS NOT NULL;
```

İşlem sonucunda 91 kayıt Customers_Cleaned tablosuna başarıyla yüklenmiştir.

 İletiler

(91 satır etkilendi)

Tamamlanma süresi:2026-05-17T15:38:09.9062481+03:00

5. Veri Kalitesi Raporu

5.1 ETL Sonrası Veri Kalitesi Analizi

ETL sürecinin tamamlanmasının ardından hedef tablodaki veri kalitesi sorgulanmıştır. Rapor; toplam kayıt sayısı, eksik değerler ve yükleme tarihi bilgilerini içermektedir.

```

SELECT
  'Customers_Cleaned' AS table_name,
  COUNT(*) AS total_rows,
  SUM(CASE WHEN Phone IS NULL THEN 1 ELSE 0 END) AS null_phone,
  SUM(CASE WHEN Region = 'N/A' THEN 1 ELSE 0 END) AS na_region,
  SUM(CASE WHEN PostalCode = 'N/A' THEN 1 ELSE 0 END) AS na_postalcode,
  SUM(CASE WHEN Country IS NULL THEN 1 ELSE 0 END) AS null_country,
  MIN(ETL_LoadDate) AS first_load,
  MAX(ETL_LoadDate) AS last_load
FROM Customers_Cleaned;

```

Sorgu sonucunda aşağıdaki tespitler yapılmıştır:

Metrik	Değer
Toplam kayıt	91
NULL telefon	0
N/A bölge	60
N/A posta kodu	1
NULL ülke	0
ETL yükleme tarihi	2026-05-17 15:38

	table_name	total_rows	null_phone	na_region	na_postalcode	null_country	first_load	last_load
1	Customers_Cleaned	91	0	60	1	0	2026-05-17 15:38:09.900	2026-05-17 15:38:09.900

6. Sonuç

Bu proje kapsamında Northwind veritabanında ETL (Extract, Transform, Load) süreci tasarlanmış ve uygulanmıştır. Yapılan çalışmalar sonucunda aşağıdaki iyileştirmeler sağlanmıştır:

- Customers, Orders ve Products tablolarındaki NULL ve tutarsız deęerler analiz edilerek tespit edilmiřtir.
- CustomerID'si "TEST" olan anlamsız test kaydı veritabanından silinmiřtir.
- NULL bölge ve posta kodu deęerleri 'N/A' ile doldurularak veri bütünlüęü saęlanmiřtır.
- Country ve ContactTitle kolonlarındaki tutarsızlıklar standartlařtırılmıřtır.
- Temizlenen veriler ETL yükleme tarihi bilgisiyle birlikte Customers_Cleaned hedef tablosuna yüklenmiřtir.
- ETL sonrası veri kalitesi raporu oluřturulmuř ve NULL ÷lke ile NULL telefon deęerlerinin tamamen giderildięi doęrulanmiřtır.

Çalıřma boyunca T-SQL'in veri temizleme ve dönüřtürme süreçlerinde ne denli etkili bir araç olduęu gör÷lmüřtür.